

MATERIA

Administración de Bases
Datos Corporativas

SEMESTRE / GRUPO

7° Semestre · Grupo M

CARRERA

Ing. en Sistemas
Computacionales

PROFESOR

Hernández Marín
Juan Carlos

ENTREGA

19 de Mayo del 2026

Análisis de la Canasta Básica

*Market Basket Analysis · Data Warehouse · ETL
Esquema Estrella · Apriori · KNN · SVM · RFM*

EQUIPO

- › Gaytan González Ángel Alejandro
- › García Hernández Jorge Eduardo
- › González Mercado Francisco Antonio
- › Guzmán Ortega José Emilio
- › Izaguirre Cortes Emanuel
- › Martínez Azuara Juan Francisco
- › Suarez Martínez Maciel Francisco

Contenido de la Presentación

01

Problemática

Dataset original y problemas del negocio

03

Fundamento Teórico

BD, SGBD, DW, ETL, Apriori, KNN, SVM, RFM

05

Flujo de la Metodología

Los 10 pasos del proceso de construcción

07

Resultados Obtenidos

Itemsets, reglas de asociación y métricas

09

Resumen Estadístico

Gráficas y KPIs clave

02

Objetivo

Qué se buscaba resolver

04

Descripción de los Datos

Características, correcciones y estructura final

06

Funcionalidades / Casos de Uso

CU-01 al CU-08

08

Interpretación de Resultados

Cumplimiento 100% de objetivos

10

Conclusión

Impacto y trabajo futuro

03 · Problemática — Problemas del Dataset Original

01

Valores nulos en descripciones

1,454 registros sin descripción de producto impedían la identificación de artículos del catálogo.

02

Clientes anónimos masivos

135,080 transacciones sin CustomerID (24.9% del total) imposibilitaban cualquier análisis de comportamiento por cliente.

03

StockCode duplicado con precios distintos

El mismo código aparecía 16,157 veces en lugar de 3,828 productos reales. Se resolvió con GROUP BY + AVG(UnitPrice).

04

Tipos de dato mixtos

InvoiceNo y StockCode mezclaban números y texto ('85123A', 71053). Requerieron conversión astype(str) antes de subir a SQL.

05

Sin variable objetivo para ML

La base no tenía etiqueta de clase ni variable supervisada, lo que impedía entrenar KNN o SVM directamente.

06

Sin atributos demográficos

Solo existía CustomerID como identificador; sin edad, género, ubicación ni nivel socioeconómico.

04 · Problemática — Problemas del Negocio



Dominancia de Ropa

La categoría Ropa aparece en prácticamente todas las reglas de asociación, opacando patrones en otras categorías.



Riesgo de Merma

Categorías de perecederos con baja frecuencia de compra generan pérdidas por inventario no rotado.



Clientes Inactivos

Alto índice de clientes sin compras recientes representa un riesgo serio de churn sin estrategia de reactivación.



Subutilización de Clientes Nuevos

Los clientes clasificados como 'Nuevos' no reciben ofertas de bienvenida ni incentivos de segunda compra.



Falta de Cross-Selling

No existe estrategia sistemática de venta cruzada entre categorías complementarias (ej. Cocina + Hogar).



Distribución de Pagos Desigual

Los métodos de pago presentan distribución heterogénea; se desaprovechan oportunidades de cobro eficiente.

05 · Objetivo General del Proyecto



Construir una base de datos empresarial simulada (RetailOnlineDB) que integre datos reales con datos sintéticos a gran escala, implemente un flujo ETL completo, ejecute Market Basket Analysis con el algoritmo Apriori, aplique segmentación RFM de clientes, y habilite la clasificación supervisada con KNN y SVM — todo documentado en 8 casos de uso funcionales con dashboards gerenciales.

Objetivos Específicos

- 1 Implementar ETL desde Excel hacia SQL Server con corrección de calidad de datos
- 2 Generar 700,000 ventas sintéticas y más de 10.5M líneas de detalle
- 3 Ejecutar Apriori con soporte mín. 1% → 590 itemsets y 2,256 reglas
- 4 Crear tabla Clientes_RFM con etiqueta Tipo_Cliente para ML supervisado
- 5 Desarrollar 8 casos de uso con reportes automáticos en PDF

06 · Fundamento Teórico — Base de Datos y SGBD

Base de Datos (BD)

Una base de datos es un sistema que consolida colecciones de datos interrelacionados, diseñados para almacenar información de forma eficiente y garantizar su accesibilidad cuando sea requerida.

- Reducción de redundancia informativa
- Accesos rápidos y seguros
- Consistencia y integridad de datos
- Soporte a sistemas transaccionales (OLTP)
- Base para estrategias data-driven

 Mercado global de análisis de datos: \$104B (2026) → \$495B (2034) · CAGR 21.5%

SGBD — Sistema Gestor de Base de Datos

El SGBD es un conjunto de instrucciones de software que facilita la extracción, almacenamiento y manipulación de datos, actuando como intermediario entre los clientes y el repositorio de datos.

- Acceso centralizado y controlado
- Gestión de concurrencia y transacciones
- Seguridad y control de permisos
- Recuperación ante fallos (backup/restore)
- Componentes: Hardware · Software · Datos · Personal

 Ejemplos: SQL Server, MySQL, Oracle, PostgreSQL, MongoDB

07 · Fundamento Teórico — Data Warehouse y Proceso ETL

Data Warehouse (DW / OLAP)

Repositorio centralizado de datos históricos integrados desde múltiples fuentes, no volátil, orientado a un tema y variante en el tiempo. Optimizado para consultas complejas y reporting estratégico (BI). Mercado 2026: \$51,180M · CAGR 10.7%.

E — Extract

Se obtienen datos de fuentes heterogéneas: ERP, CRM, Excel, APIs, archivos planos. Sin modificar los sistemas origen.

T — Transform


Limpieza de nulos, eliminación de duplicados, normalización de formatos, cálculo de valores derivados y generación de llaves.

L — Load

Carga incremental o completa hacia el Data Warehouse o base de datos destino. Se usa batch o streaming según la necesidad.

08 · Fundamento Teórico — Esquema Estrella y Data Warehouse

El esquema estrella es el modelo multidimensional clásico de un Data Warehouse: una tabla de hechos central conectada a múltiples tablas de dimensión. Permite consultas analíticas rápidas al evitar joins complejos.



Aspecto	OLTP (BD Operacional)	OLAP (Data Warehouse)
Propósito	Transacciones diarias en tiempo real	Análisis histórico y reporting estratégico
Datos	Actuales y operativos	Históricos integrados de múltiples fuentes
Estructura	Normalizada (3NF)	Desnormalizada (estrella/copo de nieve)
Usuarios	Personal operativo	Analistas, ejecutivos, data scientists

09 · Fundamento Teórico — Market Basket Analysis

Técnica de minería de datos que descubre asociaciones entre productos comprados juntos con mayor frecuencia de lo esperado al azar.
Fundamento del análisis de la canasta básica.

Las 6 Etapas del Market Basket Analysis

1

Preparación de datos

Recopilar transacciones y estructurarlas en matriz transacción × producto

3

Conjuntos frecuentes

Identificar itemsets que superen el umbral de soporte mínimo (Apriori)

5

Evaluación de reglas

Filtrar reglas usando confianza, lift y otras métricas de interés

2

Cálculo de medidas

Calcular frecuencia de co-ocurrencia y soporte de cada combinación

4

Reglas de asociación

Generar reglas Antecedente → Consecuente con umbral de confianza

6

Interpretación

Analizar patrones para decisiones de negocio (promociones, layout, stock)

10 · Fundamento Teórico — Soporte, Confianza y Lift

Soporte (Support)

$$\text{Soporte}(A) = \frac{\text{Transacciones con } A}{\text{Total transacciones}}$$

Mide la frecuencia relativa con que aparece un conjunto de productos en el dataset. Indica qué tan común es una combinación.

Ej: $\text{Soporte}(\{\text{Leche}, \text{Pan}\}) = 0.05 \rightarrow$ aparece en el 5% de las transacciones

Rango: 0 a 1 · Proyecto: mín. 1% ($\geq 4,000$ transacciones)

Confianza (Confidence)

$$\text{Confianza}(A \rightarrow B) = \frac{\text{Soporte}(A \cup B)}{\text{Soporte}(A)}$$

Probabilidad de que el producto B se compre cuando se adquiere A. Mide la fuerza predictiva de la regla.

Ej: $\text{Conf}(\text{Leche} \rightarrow \text{Pan}) = 0.7 \rightarrow$ 70% de quienes compran leche también compran pan

Rango: 0 a 1 · Proyecto: mín. 30%, máx. 99.2%

Lift (Elevación)

$$\text{Lift}(A \rightarrow B) = \frac{\text{Soporte}(A \cup B)}{[\text{Soporte}(A) \times \text{Soporte}(B)]}$$


Compara la co-ocurrencia observada con la esperada si A y B fueran independientes. Detecta asociaciones reales vs casuales.

Ej: $\text{Lift} > 1 =$ asociación positiva · $\text{Lift} = 1 =$ independencia · $\text{Lift} < 1 =$ sustitución

Proyecto: 573 reglas $\text{Lift} > 1$ · 280 reglas $\text{Lift} < 1$

11 · Fundamento Teórico — Algoritmo Apriori

Técnica de minería de datos para extraer conjuntos de elementos frecuentes y generar reglas de asociación. Principio fundamental: cualquier subconjunto de un itemset frecuente debe ser también frecuente.



12 · Fundamento Teórico — KNN y SVM

K-Nearest Neighbors (KNN)

Algoritmo de clasificación supervisada que predice la clase de un nuevo punto basándose en los K vecinos más cercanos en el espacio de atributos. La clase más frecuente entre esos K vecinos es la predicción.

Requisitos para KNN:

- Atributos numéricos o convertibles a números
- Normalización/estandarización de escalas
- Variable objetivo (etiqueta) bien definida
- Suficientes datos por clase (representatividad)

*En proyecto: Tipo_Cliente (VIP/Regular/Nuevo/Inactivo)
como etiqueta con features RFM normalizados*

Support Vector Machine (SVM)

Algoritmo que busca el hiperplano óptimo que separa dos o más clases con el máximo margen posible. Especialmente poderoso para clasificación binaria y datos de alta dimensionalidad.

Requisitos para SVM:

- Variables numéricas normalizadas (muy sensible a escala)
- Variable objetivo binaria o multiclase definida
- Sin valores nulos ni texto sin transformar
- Suficientes ejemplos por clase (evitar sesgo)

*Normalización: Min-Max (0 a 1) o Z-Score (media 0, $\sigma=1$)
aplicada en preprocesamiento antes del entrenamiento*

13 · Fundamento Teórico — Modelo RFM de Segmentación

Modelo estándar de la industria retail para caracterizar el comportamiento de compra. Las siglas significan Recencia, Frecuencia y Valor Monetario. Sus métricas son numéricas y continuas → features perfectos para KNN y SVM.

R — Recencia

Días transcurridos desde la última compra del cliente. Un cliente que compró ayer es más valioso que uno que compró hace un año. R bajo = cliente activo.

 `R = DATEDIFF(hoy, última_compra)`

F — Frecuencia

Número de compras realizadas en un período. La frecuencia alta indica fidelidad y habituación de compra en la tienda.

 `F = COUNT(DISTINCT VentaID)`

M — Monto

Total de dinero gastado por el cliente. Clientes de alto valor monetario merecen estrategias diferenciadas (programas VIP, atención personalizada).

 `M = SUM(Total) de todas sus ventas`

Segmentos Generados en el Proyecto:

Segmento	Criterio RFM	Estrategia
VIP	R bajo + F alta + M alto	Programa de lealtad premium, acceso anticipado
Regular	R/F/M moderados	Ofertas de cross-selling, descuentos por volumen
Nuevo	Primera o segunda compra	Incentivos de bienvenida, segunda compra
Inactivo	R muy alto (no compra)	Campaña de reactivación personalizada (CU-08)

14 · Descripción de los Datos — Dataset Original

Fuente: Online Retail Dataset · UCI Machine Learning Repository · Kaggle

<https://www.kaggle.com/datasets/lakshmi25npathi/online-retail-dataset>

Columna	Tipo	Descripción
InvoiceNo	String	Número de factura. Prefijo 'C' indica devolución/cancelación
StockCode	String	Código único de producto (alfanumérico)
Description	String	Nombre del producto — 1,454 valores nulos
Quantity	Integer	Unidades por transacción. Negativo = devolución
InvoiceDate	DateTime	Fecha y hora de la transacción
UnitPrice	Float	Precio unitario en libras esterlinas (£)
CustomerID	Float	ID del cliente — 135,080 nulos (compras anónimas)
Country	String	País de origen del cliente

541,909

Transacciones
originales

3,828

Productos
reales únicos

37

Países
representados

2010-2011

Período
cubierto

15 · Descripción de los Datos — Correcciones Aplicadas

01

Eliminación de nulos en Description

✗ Antes: 1,454 filas sin descripción de producto

✓ Después: Registros eliminados para evitar itemsets vacíos en el análisis

02

Tratamiento de clientes anónimos

✗ Antes: 135,080 transacciones sin CustomerID (24.9%)

✓ Después: Filtradas del análisis RFM; conservadas para Apriori (no requieren ID)

03

Deduplicación de StockCode

✗ Antes: 16,157 registros por código en lugar de 3,828 únicos con precios distintos

✓ Después: GROUP BY StockCode + AVG(UnitPrice) → catálogo limpio de 3,828 productos base

04

Corrección de tipos de dato

✗ Antes: InvoiceNo y StockCode mezclaban int y str ('85123A', 71053)

✓ Después: Conversión astype(str) antes de subir a SQL Server con SQLAlchemy

05

Generación de datos sintéticos

✗ Antes: 541,909 filas reales insuficientes para simular escala corporativa

✓ Después: Scripts Python generaron 700K ventas + 10.5M detalles + 100K transacciones

16 · Descripción de los Datos — Estructura Final de la BD (RetailOnlineDB v2)

Tabla	Registros	Descripción	Estado
Categorías	12	12 categorías de producto con FK en Productos	✓ COMPLETA
Productos	8,739	Catálogo con marca real, categoría, presentación y precio coherente	✓ COMPLETA
Clientes	5,000	Perfil demográfico: nombre, edad, género, ciudad, estado, nivel socioeconómico	✓ COMPLETA
Vendedores	20	Nombre y sucursal en zona conurbada Tampico-Madero-Altamira	✓ COMPLETA
Ventas	400,000	Encabezado de venta: fecha, cliente, vendedor, total, método de pago	✓ COMPLETA
Detalle_Ventas	~7,400,000	12-25 productos por venta con cantidad, precio unitario y subtotal	✓ COMPLETA
Clientes_RFM	5,000	Recencia, Frecuencia, MontoTotal, TicketPromedio y etiqueta Tipo_Cliente	✓ COMPLETA

>12.1M

Registros
totales en BD

7 tablas

Estructura
final

12 categ.

Categorías de
producto

Esquema ★

Arquitectura
Data Warehouse

17 · Flujo de la Metodología — Pasos 1 a 5 (Construcción de la BD)

1

Excel_a_sqlserver_local.py

→ 541,909 filas reales cargadas

💡 ETL: Extract del Excel → Transform (tipos) → Load a SQL Server

2

Generar_10k_productos.py

→ Catálogo inicial con 10,000 productos

💡 Datos sintéticos: combina tipo, color, material, talla con `np.random`

3

Agregar_15k_productos.py

→ Catálogo expandido a 25,000 productos

💡 Append sin reemplazar: `if_exists='append' + MAX(ProductoID)`

4

Generar_200k_ventas.py

→ 200K ventas + ~3.5M líneas de detalle

💡 Genera Ventas y Detalle_Ventas relacionadas: 12-25 productos/venta

5

Agregar_500k_ventas.py

→ Total: 700K ventas + ~10.5M detalles

💡 Bloques de 50K para evitar saturar RAM; continúa secuencia de IDs

18 · Flujo de la Metodología — Pasos 6 a 10 (Análisis y Resultados)

6

Generar_transacciones.py

→ 100,000 transacciones en formato Online Retail original

💡 10% sin CustomerID simulando compras anónimas; usa productos y países reales

7

Análisis de Atributos Faltantes

→ Identificación de 7 atributos críticos ausentes

💡 Sin variable objetivo, sin demografía, sin RFM → BD insuficiente para KNN/SVM

8

Reestructuración → RetailOnlineDB v2

→ Tablas: Categorías, Clientes, Vendedores, Clientes_RFM

💡 Se crea etiqueta Tipo_Cliente con percentiles dinámicos de Recencia, Frecuencia y Monto

9

Ejecución Algoritmo Apriori (mlxtend)

→ 590 itemsets + 2,256 reglas de asociación

💡 Soporte mín. 1% · Confianza mín. 30% · max_len=5 · 400K transacciones analizadas

10

Generación de Reportes y CUs

→ 8 casos de uso con dashboards en PDF automáticos

💡 Módulos reportGenerator.js y reportTemplates.js con paletas de color por segmento

19 · Funcionalidades — Casos de Uso CU-01 a CU-04

CU-01

Explorar el Catálogo de Productos

 Actor: Cliente / Gerente

Búsqueda de productos por nombre, categoría y precio. Filtrado interactivo del catálogo de 8,739 artículos.

 *Búsqueda 'Leche' → muestra todas las presentaciones disponibles con precios y categoría*

CU-02

Recomendaciones Automáticas

 Actor: Cliente / Sistema

Sugerencias basadas en reglas Apriori. Si el cliente tiene Ropa en carrito → recomienda complementos con Lift > 1.

 *Asociaciones por categoría: 573 reglas positivas disponibles para cross-selling en tiempo real*

CU-03

Ofertas Personalizadas al Pago

 Actor: Cliente / Sistema

Descuentos aplicados en checkout según segmento RFM del cliente (VIP, Regular, Nuevo, Inactivo).

 *VIP → 15% en siguiente compra · Nuevo → 10% bienvenida · Inactivo → oferta reactivación*

CU-04

Combos para Reducir Merma

 Actor: Gerente / Sistema

Genera combos inteligentes de productos perecederos con baja frecuencia para reducir pérdidas por vencimiento.

 *Combo Lácteos+Verduras → precio especial para acelerar rotación de inventario en riesgo*

20 · Funcionalidades — Casos de Uso CU-05 a CU-08

CU-05

Clasificación de Clientes (RFM)

 Actor: Gerente / Sistema

Segmentación automática de 5,000 clientes en VIP, Regular, Nuevo e Inactivo usando percentiles de RFM.

 *Clientes_RFM: Recencia (días), Frecuencia (compras), MontoTotal (\$), TicketPromedio (\$), Tipo_Cliente*

CU-06

Análisis Apriori (Reglas de Asociación)

 Actor: Gerente / Sistema

Ejecuta Market Basket Analysis: genera itemsets de tamaño 1-5 y reglas con Soporte, Confianza y Lift.

 *590 itemsets frecuentes → 2,256 reglas generadas con mlxtend, ordenadas por Lift descendente*

CU-07

Reporte General por Segmento (Dashboard)

 Actor: Gerente

Dashboard gerencial con métricas consolidadas por segmento RFM: ventas, ticket promedio, tendencias.

 *Módulo reportGenerator.js con paletas de color por segmento; exporta PDF automáticamente*

CU-08

Campaña de Reactivación de Clientes


 Actor: Gerente / Marketing

Identifica clientes Inactivos y genera mensajes de reactivación personalizados con ofertas dirigidas.

 *Clientes sin compra en 90+ días → campaña con oferta 20% en categoría más comprada históricamente*

21 · Resultados — Itemsets Frecuentes por Tamaño

El algoritmo Apriori se ejecutó sobre 400,000 transacciones con soporte mínimo de 1% y tamaño máximo de itemset 5. Se obtuvieron 590 itemsets frecuentes distribuidos así:




Tamaño	Cant.	Descripción
1	12	Categorías individuales frecuentes
2	66	Pares de categorías co-compradas
3	173	Tríos de categorías frecuentes
4	216	Conjuntos de 4 categorías (máximo)
5	123	Conjuntos de 5 categorías
TOTAL	590	Itemsets frecuentes totales

Interpretación

El tamaño 4 tiene el mayor número de itemsets (216), lo que indica que las combinaciones de 4 categorías son las más ricas en patrones de compra conjunta.

22 · Resultados — Reglas de Asociación y Métricas

Distribución de Reglas por Lift



Parámetro	Valor
Transacciones analizadas	400,000
Soporte mínimo	1% (≥ 4,000 transacciones)
Confianza mínima	30%
Confianza máxima alcanzada	99.2%
Tamaño máximo de itemset	5 categorías
Total de itemsets	590
Total de reglas generadas	2,256
Reglas con Lift > 1	573 (25.4%)
Reglas con Lift < 1	280 (12.4%)
Reglas con Lift = 1	1,403 (62.2%)

Ejemplos de Reglas de Asociación Generadas

{Ropa} → {Calzado} · Soporte: 8.2% · Confianza: 72% · Lift: 1.38
{Cocina, Hogar} → {Electrónica} · Soporte: 2.1% · Confianza: 45% · Lift: 1.92
{Ropa, Accesorios, Calzado} → {Deportes} · Confianza: 38% · Lift: 1.15

23 · Interpretación — Cumplimiento de Atributos Faltantes (7/7 = 100%)

Variable objetivo (etiqueta)

CRÍTICO

✓ CUMPLIDO

Cientes_RFM.Tipo_Cliente con 4 clases: VIP, Regular, Nuevo, Inactivo. Calculada con percentiles dinámicos de RFM.

Categoría de producto (codificada)

CRÍTICO

✓ CUMPLIDO

Tabla Categorías con 12 categorías y FK en Productos.CategorialD. Cada producto pertenece a exactamente una categoría.

Atributos demográficos del cliente

CRÍTICO

✓ CUMPLIDO

Tabla Clientes: Nombre, Edad, Género, Ciudad, Estado, NivelSocioeconomico, FechaRegistro. 5,000 registros realistas.

Métricas RFM precalculadas

IMPORTANTE

✓ CUMPLIDO

Tabla Clientes_RFM: Recencia (días), Frecuencia (compras), MontoTotal (\$), TicketPromedio (\$). Calculado desde Ventas.

Antigüedad del cliente

IMPORTANTE

✓ CUMPLIDO

Clientes.FechaRegistro. La antigüedad se calcula con DATEDIFF(DAY, FechaRegistro, GETDATE()).

Variables numéricas normalizadas

RECOMENDABLE

✓ CUMPLIDO

Preprocesamiento con Min-Max / Z-Score disponible. Evita sesgo por escala en KNN y SVM.

Indicador devolución/cancelación

RECOMENDABLE

✓ CUMPLIDO

InvoiceNo con prefijo 'C' en Online_Retail identifica cancelaciones. Columna disponible para enriquecer perfil.

24 · Interpretación — Cumplimiento 6 Etapas MBA y 3 Métricas (100%)

6 Etapas del Market Basket Analysis

1	Preparación 400K transacciones → matriz VentaID × Categoría con TransactionEncoder
2	Medidas Soporte calculado por Apriori. Soporte mín. 1%. Ningún soporte es 0.
3	Conjuntos Apriori max_len=5 → 12+66+173+216+123 = 590 itemsets
4	Reglas association_rules() con confianza mín. 30% → 2,256 reglas
5	Evaluación Soporte + Confianza + Lift por cada regla. 573 reglas Lift>1
6	Interpretación Reportes ordenados por Lift. 3 métricas documentadas y calculadas

3 Métricas + Pasos Apriori

Soporte	Mín. 1% · ≥4,000 transacciones · Ningún soporte=0	✓ CUMPLIDA
Confianza	Mín. 30% · Máx. 99.2% · 2,256 reglas calculadas	✓ CUMPLIDA
Lift	573 reglas Lift>1 (positivo) · 280 reglas Lift<1 (sustitución)	✓ CUMPLIDA

Pasos Apriori (5/5 cumplidos):


✓ Paso 1: Ítems frecuentes individuales
✓ Paso 2: Unión (Join k+1)
✓ Paso 3: Poda (Prune)
✓ Paso 4: Repetición hasta convergencia
✓ Paso 5: Generación de reglas de asociación

KNN y SVM — Habilitados


Clientes_RFM con etiqueta Tipo_Cliente (4 clases). Features: Recencia, Frecuencia, MontoTotal, TicketPromedio. Variables normalizables. Sin nulos.

25 · Resumen Estadístico del Proyecto

Itemsets Frecuentes por Tamaño



Reglas por Tipo de Lift (2,256 reglas)



>12.1M

Registros
totales BD

700K

Ventas
generadas

5,000

Clientes
segmentados

8,739

Productos
catálogo

590

Itemsets
frecuentes

2,256

Reglas de
asociación

7/7

Atributos
cumplidos

100%

Objetivos
logrados

26 · Conclusión



Cumplimiento total

RetailOnlineDB v2 cumplió al 100% los 7 atributos críticos, las 6 etapas de MBA, las 3 métricas fundamentales y los 5 pasos de Apriori.



Apriori ejecutado con éxito

590 itemsets frecuentes y 2,256 reglas de asociación sobre 400K transacciones. 573 reglas con Lift > 1 revelan patrones reales de compra cruzada.



Segmentación RFM implementada

5,000 clientes clasificados en VIP, Regular, Nuevo e Inactivo. Tabla Clientes_RFM habilita estrategias personalizadas de marketing



Arquitectura empresarial robusta

Esquema estrella con +12.1M de registros: Categorías, Productos, Clientes, Vendedores, Ventas, Detalle_Ventas y Clientes_RFM.